Ecommerce ETL

2026.09 · 개인 프로젝트 | 담당: 원천별 수집 · 스키마 매핑 · 품질 검사 · 로컬 적재

서로 다른 주문 데이터를 같은 계약으로

PG CSV·오픈마켓 HTTP API·GA4 보고서의 다른 구조를 주문 라인 단위로 통합합니다. 합성 데이터와 목업을 사용해 수집부터 DuckDB 적재까지 재현합니다.

원천별 수집 분리

Airflow DAG 3개로 각 원천의 입력과 실패 지점을 나눕니다.

18컬럼 통합 계약

source 포함 키 · UTC 시각 · KST 기준일 · 정수 KRW를 사용합니다.

날짜별 재적재

품질 검사 후 트랜잭션으로 대상 날짜를 교체합니다.

기술 구성 Python · Airflow · pandas · PyArrow / Parquet · DuckDB · Docker Compose

세 원천의 staging을 모아 날짜 단위로 적재

Ecommerce ETL | 구조와 설계 판단

원천별 수집

PG 주문
합성 CSV

+

오픈마켓
로컬 목업 HTTP

+

GA4 구매
목업 보고서 JSON

→

공통 staging
18컬럼 · Parquet

앞의 세 원천은 병렬 입력입니다. 실제 GA4 API 연결과 실제 거래 간 중복 제거는 별도 범위입니다.

수동 통합 적재

원천 결과 확인
세 소스 날짜별 파일

→

통합 품질 검사
필수값 · 키 · 날짜 · 금액

→

DuckDB
날짜 DELETE + INSERT

→

분석 화면
서비스 연동은 후속

warehouse_orders_load는 별도 수동 실행 DAG입니다. BigQuery는 설계 목표로 남겨두었습니다.

Q1–Q3
필수값 · 라인 키 중복 · 수량·금액 범위

Q4–Q7
금액 산식 · KST 날짜 · source · 미래 시각

리뷰·재현
이슈·계획·Draft PR·리뷰·머지 / venv·Docker

수집·품질·적재의 검증 범위를 확인

Ecommerce ETL | 발표용 운영 화면 · 실시간 연동 없음

3개
원천별 수집 DAG

18개
통합 주문 컬럼

152행
기존 E2E 기록

0건
기존 재실행 중복 기록

처리 상태를 읽는 기준

수집 DAG 3개
PG 46행 · 오픈마켓 45행 · GA4 61행

통합 DAG 1개
152행 · 2회 실행 · 다른 날짜 1개 보존

Q1–Q7 검사
위반률 0.00% / 임계 1% · 원본 기록

결과 · 근거 · 운영 기록

· 기존 Docker E2E 대상일: 2026-09-01 · 실시간 아님

· 09.15 pytest: 91 통과·1 스킵 (Airflow 미설치)

· 재실행 검증은 정상 입력 기준 · 날짜 교체 경계 존재

· BigQuery·GA4 실연결·서비스 분석 화면은 후속

합성·목업 데이터의 기존 E2E 결과입니다. 적재 함수 직접 호출의 대상일 혼입·부분 입력·동시 실행은 추가 검증이 필요하며 합산 금액은 총매출이 아닙니다.